



教育经历

| 智能科学与技术 | 全日制本科

2023年09月 - 2027年06月

主修科目：人工智能与机器学习、自然语言处理、智能控制导论、神经网络、智能信息处理、机器人导论、智能科学数学基础

专业技能

AI 大模型应用

- Prompt Engineering：熟悉 Few-shot、Chain-of-Thought 等技巧优化模型输出；
- RAG 流程：掌握文档向量化、混合检索、置信度分级等工程化落地能力；
- Agent 开发：掌握 ReAct 工作流设计，使用 LangGraph 实现可控的 Agent 循环（条件边 + 递归限制）；
- 框架与平台：了解 LangChain 框架底层逻辑，熟悉 Dify、Coze 这类低代码搭建Agent 与工作流的平台；
- 向量数据库：使用 Chroma 作为向量存储，在项目中实践了混合检索（向量 + BM25）与重排序策略；
- 工具：Git 版本控制、Streamlit 快速原型开发、FastAPI 基础接口开发；

Java 后端开发

- 熟练使用SpringMVC、SpringBoot、Mybatis等主流框架，可以根据需求快速搭建项目；
- 熟悉SpringIOC、AOP原理及SpringBoot自动装配原理；
- 熟悉MySQL的底层结构、存储引擎、事务、索引、锁、日志、MVCC工作原理等，具有一定的SQL调优经验；
- 熟练使用Redis，可以灵活运用常用的数据类型，熟悉缓存雪崩、缓存穿透、缓存击穿等问题的造成原因及解决思路；
- 熟悉Redis持久化以及集群方案，能够使用Redisson实现分布式锁；
- 熟悉RocketMQ消息队列，熟悉延迟消息、消息幂等及事务消息等相关技术的原理和使用；
- 熟悉JVM内存模型，熟悉类加载机制、垃圾回收算法、垃圾回收机制，有JVM项目实战调优经验；
- 熟悉Java的并发机制，熟练使用synchronized、ReentrantLock、ThreadLocal等并发工具类；

项目经验

智能售货机管理平台

AI应用开发

项目描述：智购柜是一款面向 B/C 端用户的智能售货机管理平台，采用五端分离架构。我负责自动补货工单调度模块，使用 XXL-Job 实现 分片任务处理，配合 Redisson 分布式锁解决多节点并发补货冲突，提升工单处理效率。

技术栈：Spring Boot + MyBatis-Plus + MySQL + Redis + XXL-Job + Redisson + LangChain + 通义千问 + Milvus

本人职责：

- AI 智能推荐：**使用 LangChain + RAG 架构，将商品信息向量化存入 Milvus 向量数据库，结合用户历史购买记录和上下文（时间、天气），通过向量检索 + 通义千问大模型生成个性化推荐和推荐理由，转化率显著提升；
- 修复切分隐藏陷阱：**发现并修复 LangChain 默认文本分割器 keep_separator=True 导致句号被推到下一 chunk 开头的隐藏陷阱，改用 is_separator_regex=True + 零宽断言正则方案，Top-3 命中率从 55% 提升至 82%；
- 两阶段检索：**实现 MMR 多样性检索 + BGE-Reranker 两阶段精排：先 fetch_k=20 大范围召回，再用 Cross-Encoder 精排 Top-4；
- 智能客服：**集成通义千问 API + RAG 检索企业知识库（FAQ、操作手册），实现 24 小时智能客服，有效降低人工客服工作量；
- JVM调优：**JVM 参数优化与 GC 调优（如新生代大小调整、新老年代比例调整等），显著提升通信服务稳定性和响应速度；自动补货工单调度：基于 XXL-Job 分布式任务调度，按售货机点位分片生成补货工单，处理 2000+ 点位日均补货任务；
- Redisson分布式锁：**使用Redisson分布式锁解决多节点并发补货冲突，保证补货数据一致性；
- 库存管理：**实时库存扣减，MySQL 乐观锁防止超卖；库存预警阈值触发自动补货申请，降低缺货率；

项目描述：基于LangChain Agent + 通义千问大模型构建的企业级智能数据分析平台。查看公司运营数据，通过自然语言描述分析需求，智能体自动完成数据提取、统计分析、可视化图表生成及分析报告导出，支持多步推理、工具治理和人机协同审核。

技术栈：Python + LangChain Agent + 通义千问 + Streamlit + Pandas + Matplotlib

本人职责：

- ReAct核心：**基于LangChain Agent框架设计 ReAct推理循环，实现自然语言、结构化分析计划、多工具链式调用的自动化数据分析流程，支持schema检查、指标计算、图表生成等6类预定义工具；
- JSON解析方案：**设计三级容错JSON解析策略（直接解析 → 正则提取 → 兜底文本）+ Prompt四重约束(角色定位 / 上下文注入 / 格式约束 / Few-shot示例)，提高大模型结构化输出成功率；
- 工具封装 + 白名单机制：**实现工具白名单 + 参数校验 + 输入注入检测机制，拦截 import、exec、os.system 等危险指令，杜绝 LLM 执行任意代码的安全风险；
- 人工介入审核：**引入Human-in-the-Loop审核机制，Agent生成计划后自动评估风险等级，高风险操作（全量导出、敏感字段访问）需人工确认，拒绝后工具链不执行并写入审计日志；
- 全链路Trace：**设计全链路Trace机制(trace_id → query → plan → 工具调用链 → 耗时)，支持按trace_id回放分析过程

实习经历

上海 科技有限公司

2025年10月 - 2026年03月

AI 应用开发工程师

- 参与公司自研 AI 相关项目 0-1 初期设计与开发，深度参与需求调研分析、系统架构搭建，保障项目核心业务逻辑落地；
- 负责公司 AI 产品功能日常迭代与性能优化，结合用户反馈和前沿技术，调优大模型应用、RAG 检索等核心模块；
- 承担项目日常运维与故障响应处理工作，快速解决大模型部署、分布式任务调度等技术故障，保障系统 7×24 小时稳定运行；

个人优势

- 熟悉**AI智能体、RAG、大模型应用**开发全流程，具备扎实的为工程落地能力，乐于跟踪前沿技术并快速应用到实际项目中。
- 具备良好的团队协作与沟通能力，能够与产品、算法、后端团队高效配合，共同完成需求分析、方案设计与项目交付。
- 对新技术保持高度敏感，擅长快速学习并实践大模型生态工具，注重代码质量与工程规范，能独立负责模块开发与优化。
- 工作积极主动，具备良好的问题排查与解决能力，在团队中能高效协作推进项目，同时持续探索AI智能体的创新应用场景。